

# 语音模型评测


## 从模型选型到产品迭代闭环

4款语音模型横评 · 60条样本Prompt迭代  
约40小时语音数据处理 · EvalFlow评测平台

宋凯 | 元宝-语音策略产品经理定向作品集

语音模型选型 · 效果评测 · 数据验证 · Bad Case分析

[github.com/kai666-song/EvalFlow](https://github.com/kai666-song/EvalFlow)



虎牙语音实践 + EvalFlow评测平台

# 语音模型的差异，不只在音色，更在能力是否可控、可评测

## 语音模型选型的三个难点

1

### 能力维度分散

指令遵循、句中标签、Voice Design与Voice Clone表现不同。

2

### 听感判断依赖口径

人工听测容易受样本、人员和场景影响，结论难复查。

3

### 批量处理错误难追溯

结构化输出异常、请求失败和不一致结果需要单独定位。

我希望解决的任务

## 让语音模型比较 成为可复查的产品实验

同一批样本 · 同一评测维度 · 原始结果保留  
既看能力边界，也看失败原因与应用条件

# 我把“好不好听”拆成三类可逐项验证的能力

## 同一框架下横向比较4款模型

1

### 指令与标签控制

测试自然语言指令、句中音频标签及组合控制能力。

2

### Voice Design

观察文本描述能否稳定生成符合预期的声音特征。

3

### Voice Clone

比较参考音频条件下的音色复现与稳定性。

#### 候选模型

**MiMo · Qwen**  
**FishAudio · VoxCPM**

不先问“谁最好”，而是记录每款模型  
在哪些任务上可用、受限或需要额外兜底

# 60条样本验证通过后，再扩展到约40小时语音数据

01 结构化协议


使用Qwen3.5-Omni-plus处理音频与参考文本，约束JSON输出。

02 小样迭代

基于60条样本完成5-6轮Prompt调整，先验证再批量运行。

03 异常处理

保留原始响应，通过一致性检查、规则匹配和断点续跑修复异常。



这段实践让我重视：评测配置要保存，版本要可追溯

|      |                                           |               |        |         |       |                                                                         |
|------|-------------------------------------------|---------------|--------|---------|-------|-------------------------------------------------------------------------|
| 问题分析 | Case 01<br>请用简洁的语言解释什么是 RAG，以及它解决了大模型的... | qwen3.7-flash | ● 执行成功 | 14.36 s | 904   | 成“相结合的技术架构。它的工作流程为：“检索 (Retrieve) → ...”                                |
|      | 同一测试样本                                    | glm-5.2       | ● 执行成功 | 20.47 s | 895   | “什么是 RAG？” RAG (检索增强生成) 可以理解为大模型的“开卷考试”，它让大模型在回答问题前，先去检索相关知识 (如企业文档、... |
|      | Case 02<br>向量检索在 RAG 中如何识别与用户问题相关的文档？     | qwen3.7-flash | ● 执行成功 | 20.42 s | 2,266 | 向量检索是 RAG (检索增强生成) 系统的“记忆外挂”，其核心思想是“将语义相似性转化为数学距离”。这个过程并非依靠关键词匹配，...    |
|      | 同一测试样本                                    | glm-5.2       | ● 执行失败 | N/A     | —     | LLM request timed out                                                   |

失败任务单独记录，不能让单个异常中断整批结果

# 我把个人评测方法做成可重复使用的平台

EvalFlow用固定数据集、统一标准和完整执行记录，支持多模型质量与效率比较。

- 01

固定数据集

保留问题、参考答案与关键词
- 02

多模型执行

受控并发，记录回答、状态与usage
- 03


统一质量评估

规则评测与LLM语义评审
- 04


报告与Bad Case

从指标回到具体失败样本

产品取舍：先验证评测闭环，再扩展平台功能



# 10个样本、20个任务完成真实双模型评测



本轮验证

86.7

两模型平均质量分

平均延迟

qwen 25.93s

glm 47.55s

如何使用这份结果

质量相近时，延迟影响交互体验  
继续回看6条质量失败样本  
判断差异来自模型还是评估口径

# 最终形成一套“场景—评测—Bad Case—迭代”的工作闭环

## 01 · 场景定义


先明确语音交互目标、核心能力与不能接受的失败。

## 02 · 统一评测

固定样本和口径，同时保留原始输出、延迟与失败记录。

## 03 · 数据迭代

从Bad Case归因，调整Prompt、数据或产品兜底，再做回归验证。



评测的价值不是给模型排名，而是持续找到下一步可验证的产品动作。